

Curs 8

Cristian Niculescu

1 Actualizare Bayesiană: șanse

1.1 Scopurile învățării

1. Să poată converti șansele în probabilitate și invers.
2. Să poată actualiza șansele a priori în șanse a posteriori folosind factori Bayes.
3. Să înțeleagă cum factorii Bayes măsoară gradul în care datele dau dovezi pentru sau împotriva ipotezelor.

1.2 Șanse

Când comparăm 2 evenimente, putem formula afirmațiile probabilistice în termeni de șanse.

Definiție. Șansele unui eveniment E versus evenimentul E' sunt raportul probabilităților lor $P(E)/P(E')$. Dacă nu se specifică evenimentul E' , al 2-lea eveniment este presupus a fi evenimentul complementar E^c . Astfel, șansele lui E sunt:

$$O(E) = \frac{P(E)}{P(E^c)}.$$

De exemplu, $O(\text{ploaie}) = 2$ înseamnă că probabilitatea de a ploua este de 2 ori probabilitatea de a nu ploua ($2/3$ versus $1/3$). Putem spune că "șansele de ploaie sunt 2 la 1".

Exemplu. Pentru o monedă corectă, $O(\text{avers}) = \frac{1/2}{1/2} = 1$. Putem spune că șansele aversului sunt 1 la 1 sau 50-50.

Exemplu. Pentru un zar standard, șansele de a da 4 sunt $\frac{1/6}{5/6} = \frac{1}{5}$. Putem spune că șansele sunt "1 la 5 pentru" sau "5 la 1 împotriva" a da un 4.

Exemplu. Probabilitatea unei perechi într-o mână de poker de 5 cărți este 0.42257. Astfel, șansele unei perechi sunt $0.42257/(1 - 0.42257) = 0.73181$.

Formule de conversie: Dacă $P(E) = p$, atunci $O(E) = \frac{p}{1-p}$. Dacă $O(E) = q$, atunci $P(E) = \frac{q}{1+q}$.

Observații:

1. A 2-a formulă provine din rezolvarea ecuației în p
 $q = p/(1 - p)$.
2. Probabilitățile sunt între 0 și 1, în timp ce șansele sunt între 0 și ∞ .
3. Proprietatea $P(E^c) = 1 - P(E)$ devine $O(E^c) = 1/O(E)$.

Exemplu. Fie F evenimentul că o mână de poker să fie ful (3 cărți de un rang și alte 2 cărți de un alt rang). Atunci $P(F) = 0.0014521$ deci $O(F) = 0.0014521/(1 - 0.0014521) = 0.0014542$.

Șansele de a nu avea ful sunt

$$O(F^c) = (1 - 0.0014521)/0.0014521 = 687.6578 = 1/O(F).$$

4. Dacă $P(E)$ sau $O(E)$ este mic, atunci $O(E) \approx P(E)$. Aceasta rezultă din formulele de conversie.

Exemplu. La exemplul din poker, unde F = "ful", am văzut că $P(F)$ și $O(F)$ diferă abia la a 6-a zecimală.

1.3 Actualizarea șanselor

1.3.1 Introducere

În actualizarea Bayesiană, am utilizat verosimilitatea datelor pentru a actualiza probabilitățile a priori ale ipotezelor la probabilități a posteriori. În limbaj de șanse, vom actualiza [șansele a priori](#) la [șanse a posteriori](#). Datele dau dovezi pentru sau împotriva unei ipoteze dacă șansele ei a posteriori sunt mai mari sau mai mici decât șansele ei a priori.

1.3.2 Exemplu: sindromul Marfan

Sindromul Marfan este o boală genetică a țesutului conjunctiv care apare la 1 din 15000 de oameni. Principalele caracteristici oculare ale sindromului Marfan includ ectopia de cristalin bilaterală, miopie și detașarea retinei. Aproximativ 70% din oamenii cu sindrom Marfan au cel puțin una din aceste caracteristici oculare, în timp ce doar 7% din oamenii fără sindrom Marfan au. (Nu garantăm acuratețea acestor numere.)

Dacă o persoană are cel puțin una din aceste caracteristici oculare, care sunt șansele să aibă sindromul Marfan?

Răspuns: Aceasta este o problemă standard de actualizare Bayesiană. Ipotezele noastre sunt:

M = "persoana are sindromul Marfan",

M^c = "persoana nu are sindromul Marfan".

Datele sunt:

F = "persoana are cel puțin o caracteristică oculară".

Știm probabilitatea a priori a lui M și verosimilitățile lui F dat fiind M sau M^c :

$$P(M) = 1/15000, P(F|M) = 0.7, P(F|M^c) = 0.07.$$

Putem calcula probabilitățile a posteriori folosind un tabel:

| hypothesis | prior | likelihood | Bayes | |
|------------|----------|------------|--------------|-----------|
| | | | numerator | posterior |
| H | $P(H)$ | $P(F H)$ | $P(F H)P(H)$ | $P(H F)$ |
| M | 0.000067 | 0.7 | 0.0000467 | 0.00066 |
| M^c | 0.999933 | 0.07 | 0.069995 | 0.99933 |
| total | 1 | | 0.07004 | 1 |

Șansele a priori sunt:

$$O(M) = \frac{P(M)}{P(M^c)} = \frac{1/15000}{14999/15000} = \frac{1}{14999} \approx 0.000067.$$

Șansele a posteriori sunt date de raportul probabilităților a posteriori sau al numărătorilor Bayes, deoarece factorul normalizator este același la numărător și la numitor.

$$O(M|F) = \frac{P(M|F)}{P(M^c|F)} = \frac{P(F|M)P(M)}{P(F|M^c)P(M^c)} = 0.000667.$$

Șansele a posteriori sunt de 10 ori mai mari decât șansele a priori. În acest sens, a avea o caracteristică oculară este o dovadă puternică în favoarea ipotezei M . Totuși, deoarece șansele a priori sunt atât de mici, este încă foarte puțin probabil ca persoana să aibă sindromul Marfan.

1.4 Factorii Bayes și puterea dovezii

Factorul 10 din exemplul precedent se numește factor Bayes.

Definiție: Pentru ipoteza H și datele D , **factorul Bayes** este raportul verosimilităților:

$$\text{factorul Bayes} = \frac{P(D|H)}{P(D|H^c)}.$$

Să vedem exact unde factorul Bayes apare în actualizarea șanselor. Avem

$$\begin{aligned} O(H|D) &= \frac{P(H|D)}{P(H^c|D)} \\ &= \frac{P(D|H)P(H)}{P(D|H^c)P(H^c)} \\ &= \frac{P(D|H)}{P(D|H^c)} \cdot \frac{P(H)}{P(H^c)} \\ &= \frac{P(D|H)}{P(D|H^c)} \cdot O(H). \end{aligned}$$

șansele a posteriori = **factorul Bayes** \times șansele a priori.

Din această formulă vedem că factorul Bayes (BF) ne spune dacă datele dau dovezi pentru sau împotriva ipotezei.

Dacă $BF > 1$, atunci șansele a posteriori sunt mai mari decât șansele a priori. Astfel, datele dau dovezi pentru ipoteză.

Dacă $BF < 1$, atunci șansele a posteriori sunt mai mici decât șansele a priori. Astfel, datele dau dovezi împotriva ipotezei.

Dacă $BF = 1$, atunci șansele a priori și a posteriori sunt egale. Astfel, datele nu dau nicio dovadă pentru sau împotriva ipotezei.

Următorul exemplu este din cartea *Information Theory, Inference, and Learning Algorithms* de David J. C. Mackay, care spune cu privire la probele dintr-un proces:

”În opinia mea, sarcina unui juriu ar trebui în general să fie a înmulți împreună rapoarte de verosimilitate evaluate cu grijă de la fiecare parte independentă de dovadă admisibilă cu o probabilitate a priori motivată la fel de grijuliu. Acest punct de vedere este împărtășit de mulți statisticieni, dar învățații judecători de apel britanici nu au fost de acord recent și în realitate au răsturnat verdictul unui proces deoarece jurații fuseseră învățați să utilizeze teorema lui Bayes pentru a trata dovezi ADN complicate.”

Exemplul 1. 2 oameni au lăsat urme de sânge la locul unei crime. Un suspect, Oliver, are grupa de sânge ”0”. Grupele de sânge ale celor 2 urme sunt ”0” (o grupă obișnuită în populația locală, având frecvența 60%) și ”AB” (o grupă rară, cu frecvența 1%). Dau aceste date (grupele ”0” și ”AB” găsite la locul crimei) dovezi în favoarea propoziției că ”Oliver a fost una dintre cele 2 persoane prezente la locul crimei”?

Răspuns: Sunt 2 ipoteze:

S = ”Oliver și o altă persoană necunoscută au fost la locul crimei”;

S^c = ”2 persoane necunoscute au fost la locul crimei”.

Datele sunt:

D = ”grupele de sânge ”0” și ”AB” au fost găsite”.

Factorul Bayes pentru prezența lui Oliver este $BF_{\text{Oliver}} = \frac{P(D|S)}{P(D|S^c)}$. Calculăm numărătorul și numitorul separat.

Datele spun că ambele grupe de sânge "0" și "AB" au fost aflate la locul crimei. Dacă Oliver a fost la locul crimei, grupa "0" ar fi acolo. Deci, $P(D|S)$ este probabilitatea că cealaltă persoană avea grupa "AB". Ni s-a spus că aceasta este 0.01, deci $P(D|S) = 0.01$.

Dacă Oliver nu a fost la locul crimei, atunci au fost 2 persoane aleatoare, una cu grupa "0" și una cu grupa "AB". Probabilitatea acestui fapt este $2 \cdot 0.6 \cdot 0.01$. Factorul 2 este deoarece sunt 2 moduri în care se poate întâmpla asta - prima persoană are grupa 0 și a 2-a grupa AB sau viceversa. (Am presupus că grupele de sânge ale celor 2 persoane sunt independente. Aceasta nu este exact adevărat, dar pentru o populație suficient de mare este destul de aproape de adevăr. Fie N_0 , numărul de oameni cu grupa 0, N_{AB} , numărul de oameni cu grupa AB și N , mărimea populației. Probabilitatea exactă este $\frac{(N_0-1) \cdot N_{AB}}{C_{N-1}^2} = \frac{2 \cdot (N_0-1) \cdot N_{AB}}{(N-1)(N-2)} = 2 \cdot \frac{0.6N-1}{N-1} \cdot \frac{0.01N}{N-2} \xrightarrow{N \rightarrow \infty} 2 \cdot 0.6 \cdot 0.01$. Aceasta arată că pentru N suficient de mare, probabilitatea este aproximativ $2 \cdot 0.6 \cdot 0.01$.) Factorul Bayes pentru prezența lui Oliver la locul crimei este

$$BF_{\text{Oliver}} = \frac{P(D|S)}{P(D|S^c)} \approx \frac{0.01}{2 \cdot 0.6 \cdot 0.01} = 0.8(3).$$

Deoarece $BF_{\text{Oliver}} < 1$, datele dau dovezi (slabe) împotriva prezenței lui Oliver la locul crimei.

Exemplul 2. Un alt suspect, Alberto, are grupa de sânge AB. Dau aceleași date dovezi în favoarea propoziției că Alberto a fost una din cele 2 persoane prezente la locul crimei?

Răspuns: Refolosind notațiile de mai sus cu Alberto în locul lui Oliver, avem:

$$BF_{\text{Alberto}} = \frac{P(D|S)}{P(D|S^c)} \approx \frac{0.6}{2 \cdot 0.6 \cdot 0.01} = 50.$$

Deoarece $BF_{\text{Alberto}} \gg 1$, datele dau o dovadă puternică în favoarea prezenței lui Alberto la locul crimei.

Observații:

1. În ambele exemple, am calculat doar factorul Bayes, nu șansele a posteriori. Pentru a le calcula pe ultimele, am avea nevoie să știm șansele a priori pentru prezența lui Oliver (sau Alberto) la locul crimei, pe baza altor dovezi.
2. Dacă 50% din populație ar fi avut grupa 0 de sânge în loc de 60%, atunci factorul Bayes al lui Oliver ar fi fost 1 (nici pentru, nici împotriva). Mai general, punctul de echilibru pentru dovezile cu grupe de sânge este când proporția grupei de sânge a suspectului din populația generală egalează proporția grupei de sânge a suspectului dintre cele aflate la locul crimei.

1.4.1 Reactualizare

Presupunem că adunăm datele în 2 etape, întâi D_1 , apoi D_2 . A posteriori finale pot fi calculate toate o dată sau în 2 etape, unde întâi actualizăm a priori folosind verosimilitățile pentru D_1 și apoi actualizăm a posteriori rezultate după prima actualizare folosind verosimilitățile pentru D_2 . Ultima abordare merge ori de câte ori verosimilitățile se înmulțesc:

$$P(D_1, D_2|H) = P(D_1|H)P(D_2|H).$$

Deoarece verosimilitățile sunt condiționate de ipoteze, spunem că D_1 și D_2 sunt **condiționat independente** dacă relația de mai sus are loc pentru orice ipoteză H .

Exemplu. Sunt 5 zaruri într-un sertar, cu 4, 6, 8, 12 și 20 de fețe (acestea sunt ipotezele). Luăm aleator un zar și-l aruncăm de 2 ori, obținând întâi 7, apoi 11. Sunt aceste rezultate condiționat independente? Dar independente?

Răspuns. Rezultatele sunt condiționat independente. De exemplu, pentru ipoteza zarului cu 8 fețe avem:

$$\begin{aligned}P(7 \text{ la aruncarea } 1 | \text{zar cu } 8 \text{ fețe}) &= 1/8, \\P(11 \text{ la aruncarea } 2 | \text{zar cu } 8 \text{ fețe}) &= 0, \\P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2 | \text{zar cu } 8 \text{ fețe}) &= 0.\end{aligned}$$

Pentru ipoteza zarului cu 20 de fețe avem:

$$\begin{aligned}P(7 \text{ la aruncarea } 1 | \text{zar cu } 20 \text{ fețe}) &= 1/20, \\P(11 \text{ la aruncarea } 2 | \text{zar cu } 20 \text{ fețe}) &= 1/20, \\P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2 | \text{zar cu } 20 \text{ fețe}) &= (1/20)^2.\end{aligned}$$

Totuși, rezultatele nu sunt independente. Adică:

$$P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2) \neq P(7 \text{ la aruncarea } 1)P(11 \text{ la aruncarea } 2).$$

Intuitiv, aceasta este deoarece 7 la aruncarea 1 ne permite să eliminăm zarurile cu 4 și 6 fețe, făcând un 11 la aruncarea 2 mai probabil. Ne verificăm intuiția calculând ambii membri. La membrul drept avem:

$$\begin{aligned}P(7 \text{ la aruncarea } 1) &= \frac{1}{5} \cdot \frac{1}{8} + \frac{1}{5} \cdot \frac{1}{12} + \frac{1}{5} \cdot \frac{1}{20} = \frac{31}{600}, \\P(11 \text{ la aruncarea } 2) &= \frac{1}{5} \cdot \frac{1}{12} + \frac{1}{5} \cdot \frac{1}{20} = \frac{2}{75}.\end{aligned}$$

Deci membrul drept este $\frac{31}{600} \cdot \frac{2}{75} = 0.0013(7)$.

Membrul stâng este:

$$\begin{aligned} & P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2) \\ &= P(11 \text{ la aruncarea } 2 | 7 \text{ la aruncarea } 1) \cdot P(7 \text{ la aruncarea } 1) \\ &= \left(\frac{10}{31} \cdot \frac{1}{12} + \frac{6}{31} \cdot \frac{1}{20} \right) \cdot \frac{31}{600} \\ &= \frac{17}{9000} = 0.001(8). \end{aligned}$$

Aici $\frac{10}{31}$ și $\frac{6}{31}$ sunt probabilitățile a posteriori ale zarurilor cu 12 și cu 20 de fețe dat fiind un 7 la aruncarea 1 (se pot calcula cu un tabel de actualizare Bayesiană).

Concluzionăm că, fără condiționarea de ipoteze, aruncările nu sunt independente.

Întorcându-ne la schema generală, dacă D_1 și D_2 sunt condiționat independente pentru H și H^c , atunci are sens să considerăm fiecare factor Bayes independent:

$$BF_i = \frac{P(D_i|H)}{P(D_i|H^c)}, i = 1, 2.$$

Șansele a priori ale lui H sunt $O(H)$. Șansele a posteriori după D_1 sunt

$$O(H|D_1) = BF_1 \cdot O(H).$$

Șansele a posteriori după D_1 și D_2 sunt

$$\begin{aligned} O(H|D_1, D_2) &= BF_2 \cdot O(H|D_1) \\ &= BF_2 \cdot BF_1 \cdot O(H). \end{aligned}$$

Actualizarea șanselor cu date noi, condiționat independente de cele vechi, se face prin înmulțirea șanselor a posteriori curente cu factorul Bayes al noilor date.

Exemplul 3. Alte simptome ale sindromului Marfan

Reamintim din exemplul de mai devreme că factorul Bayes pentru cel puțin o caracteristică oculară (F) este

$$BF_F = \frac{P(F|M)}{P(F|M^c)} = \frac{0.7}{0.07} = 10.$$

Semnul închieturii mâinii (W) este capacitatea de a înfășura o mână în jurul celeilalte închieturi a mâinii astfel încât unghia degetului mic să poată fi acoperită de degetul mare. Presupunem că 10% din populație are semnul

închieturii mâinii, în timp ce 90% din oamenii cu sindromul Marfan îl au. De aceea, factorul Bayes pentru semnul închieturii mâinii este

$$BF_W = \frac{P(W|M)}{P(W|M^c)} = \frac{0.9}{0.1} = 9.$$

Presupunem că F și W sunt simptome condiționat independente. Adică, printre oamenii cu sindromul Marfan, caracteristicile oculare și semnul închieturii mâinii sunt independente și printre oamenii fără sindromul Marfan, caracteristicile oculare și semnul închieturii mâinii sunt independente. Cu această presupunere, șansele a posteriori ale sindromului Marfan pentru cineva care are atât caracteristicile oculare cât și semnul închieturii mâinii sunt

$$O(M|F, W) = BF_W \cdot BF_F \cdot O(M) = 9 \cdot 10 \cdot \frac{1}{14999} \approx \frac{6}{1000}.$$

Putem converti șansele posterioare în probabilitate, dar, deoarece șansele sunt atât de mici, rezultatul este aproape același:

$$P(M|F, W) \approx \frac{6}{1000 + 6} \approx 0.596\%.$$

Așadar, caracteristicile oculare și semnul închieturii sunt ambele dovezi puternice în favoarea ipotezei M și, luate împreună, sunt dovezi foarte puternice. Din nou, deoarece șansele a priori sunt atât de mici, este încă improbabil că persoana are sindromul Marfan, dar în această situație merită să fie făcute alte teste date fiind consecințele potențial fatale ale bolii (ca anevrismul aortic sau disecția aortică).

Observăm de asemenea că, dacă o persoană are exact unul din cele 2 simptome, atunci produsul factorilor Bayes este aproape de 1 (9/10 sau 10/9). Astfel, cele 2 părți ale datelor se anulează una pe alta în ce privește dovezile pe care le dau pentru sindromul Marfan.

1.5 Log șanse

În practică, este adesea convenabil a lucra cu logaritmi naturali ai șanselor în locul șanselor. Destul de firesc, aceștia sunt numiți [log șanse](#). Formula de actualizare Bayesiană

$$O(H|D_1, D_2) = BF_2 \cdot BF_1 \cdot O(H)$$

devine

$$\ln(O(H|D_1, D_2)) = \ln(BF_2) + \ln(BF_1) + \ln(O(H)).$$

Putem interpreta formula de mai sus pentru log șansele a posteriori ca suma log șanselor a priori cu toate dovezile $\ln(BF_i)$ furnizate de date. Luând logaritmi, dovezile pentru ($BF_i > 1$) sunt pozitive și dovezile împotriva ($BF_i < 1$) sunt negative. Log șansele joacă de asemenea un rol central în regresia logistică, un model statistic legat de regresia liniară.

2 Actualizare Bayesiană cu a priori continue

2.1 Scopurile învățării

1. Să înțeleagă o familie parametrizată de repartiții ca reprezentând un domeniu continuu de ipoteze pentru datele observate.
2. Să poată să enunțe teorema lui Bayes și legea probabilității totale pentru densități continue.
3. Să poată să aplice teorema lui Bayes pentru a actualiza o funcție densitate de probabilitate a priori la o pdf a posteriori cunoscând datele și funcția de verosimilitate.
4. Să poată interpreta și calcula probabilități predictive a posteriori.

2.2 Introducere

Până acum am făcut actualizare Bayesiană când aveam un număr finit de ipoteze, de pildă exemplul nostru cu zaruri avea 5 ipoteze (4, 6, 8, 12 sau 20 de fețe). Acum vom studia actualizare Bayesiană când există un **domeniu continuu de ipoteze**. Procesul de actualizare Bayesiană va fi în esență același ca în cazul discret. Ca de obicei când ne mișcăm de la discret la continuu vom avea nevoie să înlocuim funcția masă de probabilitate cu o funcție densitate de probabilitate și sumele cu integrale.

Primele câteva secțiuni ale acestui curs sunt dedicate lucrului cu pdf-uri. În particular, vom cuprinde legea probabilității totale și teorema lui Bayes. Acestea sunt în esență identice cu versiunile discrete. Apoi, vom aplica teorema lui Bayes și legea probabilității totale pentru actualizare Bayesiană.

2.3 Exemple cu domenii continue de ipoteze

Iată 3 exemple standard cu domenii continue de ipoteze.

Exemplul 1. Presupunem că avem un sistem care poate reuși (sau eșua) cu probabilitatea p . Atunci putem face ipotezele că p este oriunde în domeniul $[0,1]$. Adică, avem un domeniu continuu de ipoteze. Adesea vom modela

acest exemplu cu o monedă cu probabilitatea p a aversului necunoscută.

Exemplul 2. Durata de viață a unui anumit izotop este modelată de o repartiție exponențială $\exp(\lambda)$. În principiu, media duratei de viață $1/\lambda$ poate fi orice număr în $(0, \infty)$.

Exemplul 3. Nu suntem restricționați la un singur parametru. În principiu, parametrii μ și σ ai unei repartiții normale pot fi orice numere reale în $(-\infty, \infty)$, respectiv în $(0, \infty)$. Dacă modelăm durata sarcinii fără gemeni printr-o repartiție normală, atunci din milioane de date știm că μ este aproximativ 40 de săptămâni și σ este aproximativ o săptămână.

În toate aceste exemple am modelat procesele aleatoare dând naștere la date printr-o repartiție cu parametri - numită **repartiție parametrizată**. Fiecare posibilă **alegere a parametrului (parametrilor) este o ipoteză**, de pildă putem face ipoteza că probabilitatea succesului în exemplul 1 este $p = 0.7313$. Avem o mulțime continuă de ipoteze deoarece am putea lua orice valoare între 0 și 1.

2.4 Convenții de notație

2.4.1 Modele parametrizate

Ca în exemplele de mai sus ipotezele noastre adesea iau forma **un anumit parametru are valoarea θ** . Vom utiliza adesea litera θ pentru o ipoteză arbitrară. Aceasta va lăsa simboluri ca p , f și x să ia sensurile lor uzuale de pmf, pdf și date. De asemenea, decât să spunem "ipoteza că parametrul de interes are valoarea θ " vom spune simplu **ipoteza θ** .

2.4.2 Litere mari și mici

Avem 2 notații paralele pentru rezultate și probabilități:

1. (**Litere mari**) Evenimentul A , funcția de probabilitate $P(A)$.
2. (**Litere mici**) Valoarea x , pmf $p(x)$, pdf $f(x)$.

Aceste notații sunt legate prin $P(X = x) = p(x)$, unde x este o valoare a variabilei aleatoare discrete X și " $X = x$ " este evenimentul corespunzător.

Ducem aceste notații la probabilitățile folosite în actualizarea Bayesiană.

1. (**Litere mari**) Din ipotezele \mathcal{H} și datele \mathcal{D} calculăm câteva probabilități asociate:

$$P(\mathcal{H}), P(\mathcal{D}), P(\mathcal{H}|\mathcal{D}), P(\mathcal{D}|\mathcal{H}).$$

În exemplul cu moneda putem avea \mathcal{H} = "moneda aleasă are probabilitatea aversului 0.6", \mathcal{D} = "aruncarea a fost avers" și $P(\mathcal{D}|\mathcal{H}) = 0.6$.

2. (**Litere mici**) Valorile ipotezei θ și valorile datelor x au ambele probabilități

sau densități de probabilitate:


$$\begin{aligned} p(\theta), p(x), p(\theta|x), p(x|\theta) \\ f(\theta), f(x), f(\theta|x), f(x|\theta) \end{aligned}$$

În exemplul cu moneda putem avea $\theta = 0.6$ și $x = 1$, astfel $p(x|\theta) = 0.6$. Putem de asemenea scrie $p(x = 1|\theta = 0.6)$ pentru a evidenția valorile lui x și θ , dar niciodată nu vom scrie doar $p(1|0.6)$ deoarece este neclar care valoare este x și care este θ .

Cu toate că încă vom folosi ambele tipuri de notații, de acum înainte vom folosi mai ales notația cu litere mici implicând pmf-uri și pdf-uri. Ipotezele vor fi de obicei parametri reprezentați de litere grecești ($\theta, \lambda, \mu, \sigma, \dots$) în timp ce valorile datelor vor fi de obicei reprezentate de litere românești (x, x_i, y, \dots).

2.5 Recapitulare rapidă a pdf și probabilității

Presupunem că X este o variabilă aleatoare cu pdf $f(x)$. Reamintim că $f(x)$ este o densitate; unitățile ei sunt probabilitate/(unitățile lui x).



Probabilitatea că valoarea lui X este în $[c, d]$ este dată de

$$\int_c^d f(x)dx.$$

Probabilitatea că X este într-un interval infinitesimal dx în jurul lui x este $f(x)dx$. De fapt, formula integrală este doar "suma" acestor probabilități infinitesimale. Putem vizualiza aceste probabilități văzând integrala ca aria de sub graficul lui $f(x)$. Pentru a manipula probabilități în loc de densități în cele ce urmează, vom utiliza frecvent noțiunea că $f(x)dx$ este probabilitatea că X este într-un interval infinitesimal în jurul lui x de lungime dx .

2.6 A priori continue, verosimilități discrete

În cadrul Bayesian avem probabilități ale ipotezelor - numite probabilități a priori și a posteriori - și probabilități ale datelor cunoscând o ipoteză - numite verosimilități. În cursurile precedente atât ipotezele cât și datele aveau domenii discrete de valori. Am văzut în introducere că putem avea

un domeniu continuu de ipoteze. Același lucru este valabil și pentru date, dar pentru acum vom presupune că datele noastre pot lua doar o mulțime discretă de valori. În acest caz, verosimilitatea datelor x cunoscând ipoteza θ este scrisă folosind o pmf: $p(x|\theta)$.

Vom utiliza următorul exemplu cu monedă pentru a explica aceste noțiuni.

Exemplul 4. Presupunem că avem o monedă cu probabilitatea aversurilor necunoscută θ . Valoarea lui θ este aleatoare și poate fi oriunde între 0 și 1. Pentru acest exemplu și pentru următoarele vom presupune că valoarea lui θ are o repartiție cu [densitatea de probabilitate a priori continuă](#) $f(\theta) = 2\theta$. Avem o [verosimilitate discretă](#) deoarece aruncarea monedei are doar 2 rezultate, $x = 1$ pentru avers și $x = 0$ pentru revers.

$$p(x = 1|\theta) = \theta, \quad p(x = 0|\theta) = 1 - \theta.$$

Gândiți: Aceasta poate fi dificil de înțeles. Avem o monedă cu o probabilitate necunoscută θ a aversului. Valoarea parametrului θ este ea însăși aleatoare și are o pdf a priori $f(\theta)$. Poate ajuta să vedem că exemplele discrete din cursurile anterioare sunt similare. De exemplu, am avut o monedă care putea avea probabilitatea aversului 0.5, 0.6 sau 0.9. Deci, puteam numi ipotezele noastre $H_{0.5}$, $H_{0.6}$, $H_{0.9}$ și acestea aveau probabilitățile a priori $P(H_{0.5})$, etc. Cu alte cuvinte, aveam o monedă cu o probabilitate necunoscută a aversurilor, aveam ipoteze despre acea probabilitate și fiecare dintre acele ipoteze aveau o probabilitate a priori.

2.7 Legea probabilității totale

Legea probabilității totale pentru repartiții de probabilitate continue este în esență aceeași ca pentru repartiții discrete. Înlocuim pmf a priori cu o pdf a priori și suma cu o integrală. Începem prin a recapitula legea pentru cazul discret.

Reamintim că pentru o mulțime discretă de ipoteze $\{\mathcal{H}_1, \mathcal{H}_2, \dots, \mathcal{H}_n\}$ legea probabilității totale spune

$$P(\mathcal{D}) = \sum_{i=1}^n P(\mathcal{D}|\mathcal{H}_i)P(\mathcal{H}_i). \quad (1)$$

Aceasta este [probabilitatea a priori](#) totală a lui \mathcal{D} deoarece am folosit probabilitățile a priori $P(\mathcal{H}_i)$.

În notațiile cu litere mici cu $\theta_1, \theta_2, \dots, \theta_n$ pentru ipoteze și x pentru date, legea probabilității totale este scrisă

$$p(x) = \sum_{i=1}^n p(x|\theta_i)p(\theta_i). \quad (2)$$

De asemenea am numit aceasta **probabilitatea predictivă a priori** a rezultatului x pentru a o distinge de probabilitatea a priori a ipotezei θ .

Analog, este o lege a probabilității totale pentru pdf continuue. O formulăm ca o teoremă folosind notația cu litere mici.

Teoremă. Legea probabilității totale. Presupunem că avem un parametru continuu θ în domeniul $[a, b]$ și datele discrete aleatoare x . Presupunem că θ este el însuși aleator cu densitatea $f(\theta)$ și că x și θ au verosimilitatea $p(x|\theta)$. În acest caz, probabilitatea totală a lui x este dată de formula

$$p(x) = \int_a^b p(x|\theta)f(\theta)d\theta. \quad (3)$$

Demonstrație. Demonstrația noastră va fi analoagă versiunii discrete: termenul de probabilitate $p(x|\theta)f(\theta)d\theta$ este perfect analog termenului $p(x|\theta_i)p(\theta_i)$ din relația 2 (sau termenului $P(\mathcal{D}|\mathcal{H}_i)P(\mathcal{H}_i)$ din relația 1). Continuând analogia: suma din relația 2 devine integrala din relația 3.

Ca în cazul discret, când gândim θ ca o ipoteză care explică probabilitatea datelor, numim $p(x)$ **probabilitatea predictivă a priori pentru x** .

Exemplul 5. Continuarea exemplului 4. Avem o monedă cu probabilitatea θ a aversului. Valoarea lui θ este aleatoare cu pdf a priori $f(\theta) = 2\theta$ pe $[0,1]$. Presupunem că aruncăm moneda o dată. Care este probabilitatea totală a aversului?

Răspuns: În exemplul 4 am observat că verosimilitățile sunt $p(x = 1|\theta) = \theta$ și $p(x = 0|\theta) = 1 - \theta$. Probabilitatea totală a lui $x = 1$ este

$$p(x = 1) = \int_0^1 p(x = 1|\theta)f(\theta)d\theta = \int_0^1 \theta \cdot 2\theta d\theta = \int_0^1 2\theta^2 d\theta = \left. \frac{2\theta^3}{3} \right|_0^1 = \frac{2}{3}.$$

2.8 Teorema lui Bayes pentru densități de probabilitate continue

Enunțul teoremei lui Bayes pentru pdf-uri continue este în esență identic cu cel pentru pmf-uri. O enunțăm incluzând $d\theta$ pentru a avea probabilități autentice:

Teoremă. Teorema lui Bayes. Folosim aceleași presupuneri ca în legea probabilității totale, i.e., θ este un parametru continuu cu pdf $f(\theta)$ și domeniul $[a, b]$; x sunt datele discrete aleatoare; împreună au verosimilitatea $p(x|\theta)$. Cu aceste presupuneri:

$$f(\theta|x)d\theta = \frac{p(x|\theta)f(\theta)d\theta}{p(x)} = \frac{p(x|\theta)f(\theta)d\theta}{\int_a^b p(x|\theta)f(\theta)d\theta}. \quad (4)$$

Demonstrație. Fie Θ variabila aleatoare care produce valoarea θ . Considerăm evenimentele

$H = "$ Θ este într-un interval de lungime $d\theta$ în jurul valorii θ "

și

$D = "$ valoarea datelor este x ".

Atunci $P(H) = f(\theta)d\theta$, $P(D) = p(x)$ și $P(D|H) = p(x|\theta)$. Din forma uzuală a teoremei lui Bayes avem

$$f(\theta|x)d\theta = P(H|D) = \frac{P(D|H)P(H)}{P(D)} = \frac{p(x|\theta)f(\theta)d\theta}{p(x)}, \text{ q.e.d.}$$

Păstrarea factorului $d\theta$ în enunțul teoremei lui Bayes este mai propice pentru a gândi în termeni de probabilități. Dar deoarece apare în toți membrii relației 4 se poate simplifica și putem scrie teorema lui Bayes în termeni de densități astfel:

$$f(\theta|x) = \frac{p(x|\theta)f(\theta)}{p(x)} = \frac{p(x|\theta)f(\theta)}{\int_a^b p(x|\theta)f(\theta)d\theta}.$$

2.9 Actualizare Bayesiană cu a priori continue

Caracteristici ale tabelului de actualizare Bayesiană pentru a priori continue:

1. Tabelul pentru a priori continue este foarte simplu: deoarece nu putem avea o linie pentru fiecare dintr-un număr infinit de ipoteze, vom avea doar o linie care folosește o variabilă pentru toate ipotezele θ .
2. Incluzând $d\theta$, toate aparițiile din tabel sunt probabilități și se aplică toate regulile de probabilități obișnuite.

Exemplul 6. (Actualizare Bayesiană.) Continuarea exemplelor 4 și 5. Avem o monedă cu probabilitate necunoscută θ a aversului. Valoarea lui θ este aleatoare cu pdf a priori $f(\theta) = 2\theta$. Presupunem că aruncăm moneda o dată și obținem avers. Calculați pdf a posteriori pentru θ .

Răspuns: Facem un tabel de actualizare cu coloanele obișnuite. Deoarece acesta este primul nostru exemplu, prima linie este versiunea abstractă a actualizării Bayesiene în general și a 2-a linie este actualizarea Bayesiană pentru acest exemplu particular. "hypothesis" = "ipoteză", "prior" = "a priori", "likelihood" = "verosimilitate", "Bayes numerator" = "numărător Bayes", "posterior" = "a posteriori".

| hypothesis | prior | likelihood | Bayes numerator | posterior |
|------------|----------------------------------|-----------------|---|-------------------------|
| θ | $f(\theta) d\theta$ | $p(x=1 \theta)$ | $p(x=1 \theta)f(\theta) d\theta$ | $f(\theta x=1) d\theta$ |
| θ | $2\theta d\theta$ | θ | $2\theta^2 d\theta$ | $3\theta^2 d\theta$ |
| total | $\int_a^b f(\theta) d\theta = 1$ | | $p(x=1) = \int_0^1 2\theta^2 d\theta = 2/3$ | 1 |

De aceea pdf a posteriori (după vederea unui avers) este $f(\theta|x) = 3\theta^2$.

Comentarii:

1. Deoarece am folosit probabilitatea a priori $f(\theta)d\theta$, ipoteza ar fi trebuit să fie:

”parametrul necunoscut este într-un interval de lungime $d\theta$ în jurul lui θ ”.

Chiar dacă este prea mult de scris pentru noi, asta trebuie să gândim de fiecare dată când scriem că ipoteza este θ .

2. Pdf a posteriori pentru θ se află înlăturând $d\theta$ din probabilitatea a posteriori din tabel.

$$f(\theta|x) = 3\theta^2.$$

3. i) $p(x)$ este probabilitatea totală. Deoarece avem o repartiție continuă, în loc de o sumă calculăm o integrală.

ii) Incluzând $d\theta$ în tabel, este clar ce integrală avem nevoie să calculăm pentru a afla probabilitatea totală $p(x)$.

4. Tabelul organizează versiunea continuă a teoremei lui Bayes. Anume, pdf a posteriori este legată de pdf a priori și verosimilitate prin

$$f(\theta|x)d\theta = \frac{p(x|\theta)f(\theta)d\theta}{\int_a^b p(x|\theta)f(\theta)d\theta} = \frac{p(x|\theta)f(\theta)d\theta}{p(x)}.$$

Împărțind la $d\theta$ avem enunțul în termeni de densități.

5. Putem exprima teorema lui Bayes în forma:

$$f(\theta|x) \propto p(x|\theta) \cdot f(\theta)$$

a posteriori \propto verosimilitatea \times a priori.

2.9.1 A priori plate

O a priori plată sau uniformă presupune că fiecare ipoteză este egal probabilă. De exemplu, dacă θ are domeniul $[0,1]$, atunci $f(\theta) = 1$ este o a priori plată.

Exemplul 7. (A priori plate.) Avem o monedă cu probabilitatea necunoscută θ a aversului. Presupunem că o aruncăm o dată și obținem revers. Presupunând o a priori plată, aflați probabilitatea a posteriori pentru θ .

Răspuns: Procedăm ca la exemplul 6, cu a priori și verosimilitatea modificate.

| hypothesis θ | prior $f(\theta) d\theta$ | likelihood $p(x=0 \theta)$ | Bayes numerator $(1-\theta) d\theta$ | posterior $f(\theta x=0) d\theta$ |
|------------------------|----------------------------------|--|---|--------------------------------------|
| θ | $1 \cdot d\theta$ | $1 - \theta$ | $(1 - \theta) d\theta$ | $2(1 - \theta) d\theta$ |
| total | $\int_a^b f(\theta) d\theta = 1$ | $p(x=0) = \int_0^1 (1 - \theta) d\theta = 1/2$ | | 1 |

2.9.2 Folosirea pdf a posteriori

Exemplul 8. În exemplul anterior probabilitatea a priori a fost plată. Întâi arătați că aceasta înseamnă că a priori moneda este egal părtinitoare spre avers sau revers. Apoi, după observarea unui avers, care este probabilitatea (a posteriori) ca moneda să fie părtinitoare spre avers?

Răspuns. Deoarece parametrul θ este probabilitatea aversului, întâi ni se cere să arătăm că $P(\theta > 0.5) = 0.5$, apoi ni se cere să calculăm $P(\theta > 0.5|x = 1)$. Acestea se calculează din pdf-urile a priori, respectiv a posteriori.

Probabilitatea a priori ca moneda să fie părtinitoare spre avers este

$$P(\theta > 0.5) = \int_{0.5}^1 f(\theta) d\theta = \int_{0.5}^1 1 d\theta = \theta|_{0.5}^1 = \frac{1}{2}.$$

Probabilitatea de $1/2$ înseamnă că moneda este egal părtinitoare spre avers sau revers.

Ca în exemplul 7 se calculează că $f(\theta|x = 1) = 2\theta$.

Probabilitatea a posteriori că moneda este părtinitoare spre avers este

$$P(\theta > 0.5|x = 1) = \int_{0.5}^1 f(\theta|x = 1) d\theta = \int_{0.5}^1 2\theta d\theta = \theta^2|_{0.5}^1 = \frac{3}{4}.$$

Vedem că observarea unui avers a crescut probabilitatea ca moneda să fie părtinitoare spre avers de la $1/2$ la $3/4$.

2.10 Probabilități predictive

La fel ca în cazul discret, suntem de asemenea interesați să folosim probabilitățile a posteriori ale ipotezelor pentru a face predicții pentru ce se va întâmpla mai departe.

Exemplul 9. (Predictie a priori și a posteriori.) Continuarea exemplelor 4, 5, 6: avem o monedă cu probabilitate necunoscută θ a aversului și valoarea

lui θ are pdf a priori $f(\theta) = 2\theta$. Aflați probabilitatea predictivă a priori a aversului. Apoi presupunând că prima aruncare a fost avers, aflați probabilitățile predictive a posteriori atât pentru avers cât și pentru revers la a 2-a aruncare.

Răspuns: Fie x_1 rezultatul primei aruncări și x_2 al celei de-a 2-a. Probabilitatea predictivă a priori este exact probabilitatea totală calculată în exemplele 5 și 6.

$$p(x = 1) = \int_0^1 p(x = 1|\theta)f(\theta)d\theta = \int_0^1 \theta \cdot 2\theta d\theta = \int_0^1 2\theta^2 d\theta = \frac{2\theta^3}{3} \Big|_0^1 = \frac{2}{3}.$$

Probabilitățile predictive a posteriori sunt probabilitățile totale calculate folosind pdf a posteriori. Din exemplul 6 știm că pdf a posteriori este $f(\theta|x_1 = 1) = 3\theta^2$. Probabilitățile predictive a posteriori sunt

$$\begin{aligned} p(x_2 = 1|x_1 = 1) &= \int_0^1 p(x_2 = 1|\theta, x_1 = 1)f(\theta|x_1 = 1)d\theta = \int_0^1 \theta \cdot 3\theta^2 d\theta \\ &= \frac{3\theta^4}{4} \Big|_0^1 = \frac{3}{4}, \end{aligned}$$

$$\begin{aligned} p(x_2 = 0|x_1 = 1) &= \int_0^1 p(x_2 = 0|\theta, x_1 = 1)f(\theta|x_1 = 1)d\theta = \int_0^1 (1 - \theta) \cdot 3\theta^2 d\theta \\ &= \left(\theta^3 - \frac{3\theta^4}{4} \right) \Big|_0^1 = \frac{1}{4}. \end{aligned}$$

(Mai simplu, puteam calcula

$$p(x_2 = 0|x_1 = 1) = 1 - p(x_2 = 1|x_1 = 1) = 1 - 3/4 = 1/4.)$$

2.11 De la actualizarea Bayesiană discretă la actualizarea Bayesiană continuă

Pentru a dezvolta intuiția pentru tranziția de la actualizarea Bayesiană discretă la actualizarea Bayesiană continuă, vom:

- i) aproxima domeniul continuu de ipoteze printr-un număr finit de ipoteze;
 - ii) crea tabelul de actualizare discretă pentru numărul finit de ipoteze;
 - iii) considera cum se schimbă tabelul când numărul de ipoteze tinde la infinit.
- În acest fel, vom vedea că pmf-urile a priori și a posteriori converg la pdf-urile a priori și a posteriori.

Exemplul 10. Pentru a păstra lucrurile concrete, vom lucra cu moneda cu o a priori plată $f(\theta) = 1$ din exemplul 7. Scopul nostru este să mergem de la discret la continuu crescând numărul de ipoteze.


4 ipoteze. Împărțim $[0,1]$ în 4 intervale egale: $[0,1/4]$, $[1/4,1/2]$, $[1/2,3/4]$, $[3/4,1]$. Fiecare interval are lungimea $\Delta\theta = 1/4$. Punem cele 4 ipoteze ale noastre θ_i în centrele celor 4 intervale:

$$\theta_1 : "\theta = 1/8", \theta_2 : "\theta = 3/8, \theta_3 : "\theta = 5/8", \theta_4 : "\theta = 7/8".$$

A priori plătim fiecărei ipoteze o probabilitate de $1/4 = 1 \cdot \Delta\theta$. Avem tabelul:

| hypothesis | prior | likelihood | Bayes num. | posterior |
|----------------|-------|------------|--------------------------------------|-----------|
| $\theta = 1/8$ | $1/4$ | $1/8$ | $(1/4) \times (1/8)$ | $1/16$ |
| $\theta = 3/8$ | $1/4$ | $3/8$ | $(1/4) \times (3/8)$ | $3/16$ |
| $\theta = 5/8$ | $1/4$ | $5/8$ | $(1/4) \times (5/8)$ | $5/16$ |
| $\theta = 7/8$ | $1/4$ | $7/8$ | $(1/4) \times (7/8)$ | $7/16$ |
| Total | 1 | — | $\sum_{i=1}^n \theta_i \Delta\theta$ | 1 |

Iată histogramele de densitate ale pmf-urilor a priori și a posteriori. Pdf-urile a priori și a posteriori din exemplul 7 sunt trasate pe histograme cu roșu.




8 ipoteze. Acum împărțim $[0,1]$ în 8 intervale, fiecare cu lungimea $\Delta\theta = 1/8$ și punem cele 8 ipoteze ale noastre θ_i în centrele celor 4 intervale:



$$\begin{aligned} \theta_1 : "\theta = 1/16", \theta_2 : "\theta = 3/16, \theta_3 : "\theta = 5/16", \theta_4 : "\theta = 7/16", \\ \theta_5 : "\theta = 9/16", \theta_6 : "\theta = 11/16, \theta_7 : "\theta = 13/16", \theta_8 : "\theta = 15/16". \end{aligned}$$

A priori plătim fiecărei ipoteze o probabilitate de $1/8 = 1 \cdot \Delta\theta$. Iată tabelul și histogramele de densitate:

| hypothesis | prior | likelihood | Bayes num. | posterior |
|------------------|-------|------------|--------------------------------------|-----------|
| $\theta = 1/16$ | 1/8 | 1/16 | $(1/8) \times (1/16)$ | 1/64 |
| $\theta = 3/16$ | 1/8 | 3/16 | $(1/8) \times (3/16)$ | 3/64 |
| $\theta = 5/16$ | 1/8 | 5/16 | $(1/8) \times (5/16)$ | 5/64 |
| $\theta = 7/16$ | 1/8 | 7/16 | $(1/8) \times (7/16)$ | 7/64 |
| $\theta = 9/16$ | 1/8 | 9/16 | $(1/8) \times (9/16)$ | 9/64 |
| $\theta = 11/16$ | 1/8 | 11/16 | $(1/8) \times (11/16)$ | 11/64 |
| $\theta = 13/16$ | 1/8 | 13/16 | $(1/8) \times (13/16)$ | 13/64 |
| $\theta = 15/16$ | 1/8 | 15/16 | $(1/8) \times (15/16)$ | 15/64 |
| Total | 1 | – | $\sum_{i=1}^n \theta_i \Delta\theta$ | 1 |



20 ipoteze. Acum împărțim $[0,1]$ în 20 de intervale. Tabelul se face analog ca în cele 2 cazuri anterioare. Sărim direct la histogramele de densitate.



Privind la reprezentări, vedem cum histogramele de densitate a priori și a posteriori converg la funcțiile densitate de probabilitate a priori și a posteriori.

3 Convenții de notație

3.1 Scopul învățării

Să poată lucra cu notațiile și termenii pe care îi folosim pentru a descrie probabilitățile și verosimilitatea.

3.2 Introducere

Am introdus un număr de notații diferite pentru probabilitate, ipoteze și date. Le adunăm aici, pentru a le avea într-un singur loc.

3.3 Notații și terminologie pentru date și ipoteze

Când am început cursul am vorbit despre rezultate (sau cazuri), de exemplu avers sau revers. Apoi, când am introdus variabilele aleatoare am dat rezultatelor valori numerice, de exemplu 1 pentru avers și 0 pentru revers. Aceasta ne-a permis să facem lucruri precum calculul mediilor și dispersiilor. Reamintim convențiile noastre de notație:

Evenimentele sunt notate cu majuscule, de exemplu A, B, C .

O variabilă aleatoare este majuscula X și ia valorile x .

Legătura dintre valori și evenimente: " $X = x$ " este evenimentul că X ia valoarea x .

Probabilitatea unui eveniment este majuscula $P(A)$.

O variabilă aleatoare discretă are funcția masă de probabilitate $p(x)$. Legătura dintre P și p este că $P(X = x) = p(x)$.

O variabilă aleatoare continuă are funcția densitate de probabilitate $f(x)$.

Legătura dintre P și f este că $P(a \leq X \leq b) = \int_a^b f(x)dx$.

Pentru o variabilă aleatoare continuă X , probabilitatea că X este într-un interval infinitesimal de lungime dx în jurul lui x este $f(x)dx$.

În contextul actualizării Bayesiene avem convenții similare.

Folosim litere mari caligrafice (de mână), în special \mathcal{H} , pentru a indica o ipoteză, de exemplu $\mathcal{H} = \text{"moneda este corectă"}$.

Folosim litere mici grecești, în special θ , pentru a indica valoarea ipotetică a unui parametru al modelului, de exemplu probabilitatea ca moneda să atearzeze avers este $\theta = 0.5$.

Folosim litere mari caligrafice (de mână), în special \mathcal{D} , când vorbim despre date ca evenimente. De exemplu, $\mathcal{D} = \text{"secvența de aruncări a fost HTH"}$.

Folosim litere mici, în special x , când vorbim despre date ca valori. De exemplu, secvența de date a fost $x_1, x_2, x_3 = 1, 0, 1$.

Când mulțimea de ipoteze este discretă, putem folosi probabilitatea ipotezelor individuale, de exemplu $p(\theta)$. Când mulțimea este continuă, trebuie să folosim probabilitatea pentru un domeniu infinitesimal de ipoteze, de exemplu $f(\theta)d\theta$.

Următorul tabel rezumă aceasta pentru θ discretă și θ continuă. În ambele cazuri presupunem o mulțime discretă de rezultate posibile (date) x .

| | | Bayes | | | |
|-----------------------|---------------|---------------------|------------------------------|--|------------------------------|
| | hypothesis | prior | likelihood | numerator | posterior |
| | \mathcal{H} | $P(\mathcal{H})$ | $P(\mathcal{D} \mathcal{H})$ | $P(\mathcal{D} \mathcal{H})P(\mathcal{H})$ | $P(\mathcal{H} \mathcal{D})$ |
| Discrete θ : | θ | $p(\theta)$ | $p(x \theta)$ | $p(x \theta)p(\theta)$ | $p(\theta x)$ |
| Continuous θ : | θ | $f(\theta) d\theta$ | $p(x \theta)$ | $p(x \theta)f(\theta) d\theta$ | $f(\theta x) d\theta$ |

Reamintim că ipoteza continuă θ este în realitate o prescurtare pentru "parametrul θ este într-un interval de lungime $d\theta$ în jurul lui θ ".